開發學術漢語詞彙測量系統的可行性研究

摘 要：來華攻讀學位的留學生持續增多，他們在專業學習中需要掌握相當數量的學術漢語詞彙，高校也需要根據學生的學術漢語詞彙水平評估其攻讀學位的能力，但目前仍缺乏相關測量工具。因此，開發學術漢語詞彙測量系統十分必要。本研究初步開發了學術漢語詞彙測量系統，旨在探究此系統的信效度。該系統基於學術漢語詞彙庫，依據詞頻、詞性和音節數抽出一定量的詞，以基於經典測量理論的自適應模型為測試框架，將其設計成學術語境中的翻譯題形式，並利用文本匹配算法與大模型輔助評分。研究結果顯示，經效標測試檢驗，最終納入測試系統的題目信效度良好，在檢測學習者學術漢語詞彙量方面具備一定可靠性;且該測試系統的評分方法所得結果與人工評分大體相符。總體結果表明，該系統可以幫助測量留學生學術漢語詞彙水平，對高校評估留學生攻讀學位的能力具有一定的參考價值。

關鍵詞：學術漢語 詞彙量測試 國際中文教育 自適應模型 自然語言處理

1 引言

「漢語熱」持續不減，世界各地學習漢語的人數不斷增加，來華攻讀學位的留學生數量也持續上升（戴曼純，2023）[1]。對於這一群體，在他們閱讀和寫作學術漢語文章中，掌握一定數量的學術漢語詞彙是十分必要的。此外，國內高校在評估留學生是否具有攻讀相應學位的能力時，也需要規範化、標準化的測量工具，特別是評估學術漢語能力的測量工具。

[1]戴曼純（主編）（2023）:《國際中文教育發展報告》，北京，外語教學與研究出版社。

近年來，學界對學術漢語的關注逐漸增加，但研究主要集中在學術漢語的定義、語篇特徵以及教學策略等方面，較少涉及詞彙層面。 即使少數研究著眼於詞彙層面，也多停留在特點分析、教學策略以及專門用途的詞表創制上。 目前，還沒有基於通用學術漢語詞彙表開發的詞彙量測試系統。

在數字化和智慧化的趨勢下，各國都在積極推動教育的數字化轉型。 同時，考慮到考試智能化的發展趨勢，研究者也可以借助智能技術，為學習者提供更加科學的漢語測評與學習系統。 基於此，在國際中文教育發展的新階段，順應數字化和智慧化的趨勢，利用智能教育技術，搭建學術漢語測試與評估系統具有重要意義，而開發學術漢語詞彙測量系統則是建設的基礎。 本研究將基於學術漢語詞彙量表，借助計算機智能技術，開發學術漢語詞彙測量系統，並從多角度評估其可行性。

2 文獻綜述

（一）詞彙量測試

根據測試維度的不同，詞彙測試通常分為接受性詞彙測試和產生性詞彙測試（Nation，2001）[2]。 接受性詞彙指的是詞彙知識的廣度，即學習者所能理解的詞彙; 而產生型詞彙指的是詞彙知識的深度，即學習者所能運用的詞彙。 學界較為注重接受性詞彙量測試的研究，研究成果較多。 在接受性詞彙量測試中，常用的形式包括翻譯題、釋義題等。 在翻譯形式中，被試需要使用其他語言（主要是母語）翻譯目的語。 而釋義題則以選擇題形式呈現，測試者需要從 6 個或

[2] Nation, I. S. P. (2001). Learning vocabulary in another language. Cambridge: Cambridge University Press.

4 個釋義中選出與目標詞匹配的釋義（Nation 和 Coxhead， 2021）[3]。 然而，釋義題形式往往會出現高估測試者水平的現象，因為測試者可以根據所提供的選項使用猜測策略或其他考試策略（Gyllstad 等，2015）[4]。

在二語領域的詞彙測試中，採用翻譯題形式的研究較少，但該形式仍具有一定的優勢。 與提供選項的釋義題相比，翻譯題形式能有效減少測試者使用考試策略作答的情況。 Webb（2017）[5]指出，翻譯法可以為接受性詞彙測試和產生性詞彙測試提供較為公平、準確的評估方法。 因此，開發以翻譯題形式為載體的詞彙量測試具有一定的意義。

（二）學術詞彙量測試

近年來，學界多關注對學術詞彙量表的開發，其中 Coxhead 開發的 Academic Word List（Coxhead 和 Averil，2000）[6]已成為學術英語領域內被廣泛使用的測量工具。 然而，近年來它也受到了一些質疑。 Gardner 和 Davies（2015）[7]提出了以 Academic Vocabulary List（AVL）代替 AWL。

目前學術詞彙量測試都為基於特定的學術詞表，使用多種形式測量學習者的學術詞彙能力。 如 Masrai 和 Milton（2018）基於 AWL，使用詞表法進行學術詞彙量測試[8]。 由於缺乏詞彙的補充信息，學術詞表的實用性常常受到限制

---

[3] Nation, I. S. P., & Coxhead, A. (2021). Measuring native-speaker vocabulary size. John Benjamins. https://doi.org/10.1075/Z.233

[4] Gyllstad, H., Vilkaite, L., & Schmitt, N. (2015). Assessing vocabulary size through multiple-choice formats: Issues with guessing and sampling rates. International Journal for Applied Linguistics, 166, 278-306.

[5] Webb, S., Sasao, Y., & Ballance, O. (2017). The updated Vocabulary Levels Test: Developing and validating two new forms of the VLT. ITL—International Journal of Applied Linguistics, 168(1), 33–69. https://doi.org/10.1075/itl.168.1.02web

[6] Coxhead, Averil (2000) A new academic word list. TESOL Quarterly 34 (2): 213-238.

[7] Gardner, D., & Davies, M. (2015). A new academic vocabulary list. Applied Linguistics, 35, 305e327.

[8] Masrai, A., & Milton, J. (2018). Measuring the contribution of academic and general vocabulary knowledge to learners' academic achievement. Journal of English for Academic Purposes, 31, 44-57.

（Thompson 和 Alzeer，2019）[9]，一些學者也嘗試通過提供詞彙的用法（Green，2019）[10]和搭配（Lei 和 Liu，2018）等，提高其實用性。

在國際中文教育領域，學術漢語的研究近年來剛剛起步。 而對學術漢語詞彙測試的研究更是少之又少，多集中於對特定專業詞彙量測量的研究。 如王笑然等人（2022）[11]通過自建的經貿專業學術漢語語料庫，提取經貿專業學術詞彙，創制了經貿專業本科生學術漢語詞彙表。

綜上所述，在國際中文教育領域，詞彙量測試近年來關注度日漸上升，但仍缺乏針對學術漢語詞彙量測試的研究。 即使在開發通用詞彙量表的研究中，也多使用釋義法呈現，缺少對更為翻譯題形式的運用。 此外，在智慧化的時代趨勢下，詞彙量測試也需要借助智能技術，滿足全球漢語學習者「隨處可學」、「隨時可測」的需求，開發較為規範、符合測量要求的測量系統。

基於此，本研究旨在開發可供漢語學習者線上使用的學術漢語測量系統，並從測量理論等多角度去檢驗該系統的信效度。

（三）自適應測試

計算機化自適應測試（Computerized Adaptive Testing ，CAT）是一種測試模式，它通過為每個測試者的具體情況制定專屬測試專案，縮短測試時長，在能力評估方面顯著提高了效率與精準度。 CAT 的核心原理是項目反應理論（Item Response Theory，IRT），即 Rasch 模型。 該模型基於一個重要假設，即所有

---

[9] Thompson, P., & Alzeer, S. (2019). A survey of issues, practices and views related to corpus-based word lists for English language teaching and learning. International Journal of Applied Linguistics & English Literature, 8, 43–53.

[10] Green， C. (2019). Enriching the academic wordlist and secondary vocabulary lists with lexicogrammar: Toward a pattern grammar of academic vocabulary. System， 87. https://doi.org/10.1016/j.system.2019.102158. Article 102158.

Lei， L.， & Liu， D. (2018). The academic English collocation list: A corpus-driven study. International Journal of Corpus Linguistics， 23， 216–243.

[11] 王笑然、王佶旻（2022）:「經貿類本科專業學術漢語詞表研究」,《語言教學與研究》（04），9-19。

題目在區分不同能力層級的被試時具有同等效力，在構建模型時主要聚焦於題目的難度以及被試的能力（Masaki，2016）[12]。 其公式如下：

$$P(X_{ij} = 1|\theta_i; \alpha_j, \beta_j, c_j) = \frac{e^{D(\theta_i - \beta_j)}}{1 + e^{D(\theta_i - \beta_j)}}$$

本研究選用單參數模型，暫不考慮區分度參數 α ，原因如下：一是初期重點在於快速構建基礎評估框架，瞭解學生在學術漢語領域的整體表現，單參數模型簡潔直觀，能迅速獲取初步結果。 二是測試題目圍繞學術漢語詞彙釋義，其專業性與複雜性使內在結構難以用區分度參數有效量化，強行引入可能致模型不準確。三是受研究資源與時間限制，多參數模型成本高，單參數模型在保證一定有效性時可減少資源投入。

在這種情況下，設區分度參數 α 設定為 1，猜測參數 c 設定為 0。 設定 θ i 參數表示第 i 位學生的能力，β j 參數表示第 j 道題目的難度，事件 X_{ij} 表示學生 i 答對了題目 j，其做對的概率如下所示：

$$P(X_{ij} = 1|\theta_i, \beta_j) = \frac{e^{D(\theta_i - \beta_j)}}{1 + e^{D(\theta_i - \beta_j)}}$$

通過這樣的模型設計與參數設定，能夠較為精準地對學生的能力進行評估與判斷。

[12] Masaki Uto, Maomi Ueno (2016) Item response theory for peer assessment. IEEE Transactions on Learning Technologies, IEEE Computer Society, Vol.9, No.2, pp.157-170. [IF: 2.315]

3 研究設計

本研究分為以下三個部分：

（一）測試項目的編製

1、目標詞的抽取

本研究以李加鎣（2024）構建的《漢語學術詞表》[13]為依據，該詞表涵蓋 698 個學術詞語及 712 個學術義，包含詞性、學術語體頻率和常見搭配等資訊。 首先，鑒於量詞、代詞、副詞、介詞、連詞、助詞等虛詞意義模糊且主要起語法功能，可能給翻譯工作造成困難（Zhang，H. 2024）[14]，本研究剔除了這些虛詞，僅保留名詞、動詞、形容詞三類詞。 接著，運用分層抽樣法，綜合詞頻、音節數和詞性，從剩餘 694 個詞中抽取 270 個詞，用於開發測試副本，以待後續使用。在兩輪測試后，依據測試者反饋和專家建議，結合信度、區分度和難易度等因素，選取 70 道區分度和難易度較好的題目納入測試系統，以檢測測試系統能否正常運行及檢驗機器評分效果。

2、翻譯題的編寫

在測試中，目標詞以翻譯題形式在半語境化句子中呈現在學術語體中。 目標詞的常用義項與日常語體中的常用義項通常存在一定差異，因此，將目標詞以學術語體中半語境的形式呈現能更好地考察學習者的學術漢語水平。

句子的編寫遵循以下標準：

（1）確保句子結構完整，提供充分語境。

（2）使用目標詞的常見搭配，提高測試真實性。

---

[13] 李加鎣（2024）:「漢語學術詞表的構建及應用」,《世界漢語教學》（03），395-406。

[14] Zhang, H., Sun, P., Bianglae, Y., & Widiawati, W. (2024). The development of a Chinese vocabulary proficiency test (CVPT) for learners of Chinese as a second/foreign language. Language Testing. https://doi.org/10.1177/02655322231219998

（3）搭配詞難度不超過目標詞，避免閱讀困難。

（4）避免文學化句子，使用普適性強的句子。

（5）控制句子長度 5-15 字，統一為單句，減少測試負擔。

（6）句子來源多樣，主要來自學術性強的材料。

3、效標測試的設計

（1）識字量測試

使用張海威等人（2021）開發的《留學生識字量表》[15]，根據被試的口頭回答情況，評估其漢語水平。 該識字量表包含 100 個漢字。 在測試過程中，每個漢字會逐個展示，被試需要為每一個字進行口頭組詞，只有當音、義均正確才算作認識該字。 正確率需達到 60%以上，才能繼續進行詞彙量測試。

（2）漢英水平自評

採用五點量表設計了《漢英水平自我評估問卷》。 被試需要從聽力、口語、閱讀、寫作、整體這五個部分對其漢語及英語水平進行 0-5 分的打分。

4、 翻譯評分及答案建立

最終納入測試系統的翻譯題答案來源於第二次測試被試所寫的答案。以《牛津高階英漢詞典》和專家建議作為參考，為本次測試確立了權威性和可信度。本測試採用二分法計分，正確翻譯得 1 分，否則得 0 分。

此外，本研究採取了相對寬鬆的評分標準，近義表述只要接近詞典釋義就算正確，書寫和語法錯誤則忽略不計。在這一評分標準下，部分目標詞可能有多個答案，對此都納入了測試系統中。

---

[15] 張海威、張雪妍、張鐵軍、王睿昕（2021）:「留學生識字量表編制研究」,《世界漢語教學》（01），126-142。

（二）自適應測試系統的開發

1、 算法基礎與實現

本研究採用基於單參數 Rasch 模型的分部評分模型（Partial Credit Model，PCM），此模型隸屬於 IRT 框架下的多級模型。 在單參數 Rasch 模型基礎上，針對題目 j 設有 K（K≥1）個步驟，依學生做對步驟數評分，j 題可評 K+1 個分值，即 K= 0，1，2，...，K 對應做對 K 個步驟。 其中，θ_i 代表第 i 位學生能力，α_j 為 j 題區分度，β_{jm} 是學生在 j 題完成 m-1 步後完成 m 步的難度。 那麼，學生 i 做對題目 j 的 K 個步驟的概率為：

$$p_{ijk} = \frac{e^{\sum_{v=0}^{K}(\theta_i - \beta_{jv})}}{\sum_{m=0}^{K-1} e^{\sum_{v=0}^{m}(\theta_i - \beta_{jv})}} (K = 0，1，2，\ldots，K-1)$$

圖 1 展示了分部評分模型的實現流程。測試從「開始測試」階段啟動，測試者隨即進入「作答題目」環節，依次完成分配的任務。 系統根據受試者的回答正確性進行動態調整：若回答錯誤，則「降低測試者水平估計」; 反之則「提升測試者水平估計」。 這一判斷迴路確保了測試難度的適時調整。 在每次作答后，系統依據受試者當前的能力水準，選擇相應難度的題目繼續測試，直至受試者水平達到穩定狀態。 最終，系統「顯示評估結果」，標誌著整個測試流程的圓滿結束。 該模型通過精準調控測試難度，有效評估受試者的真實能力，確保了評估結果的準確性和科學性。

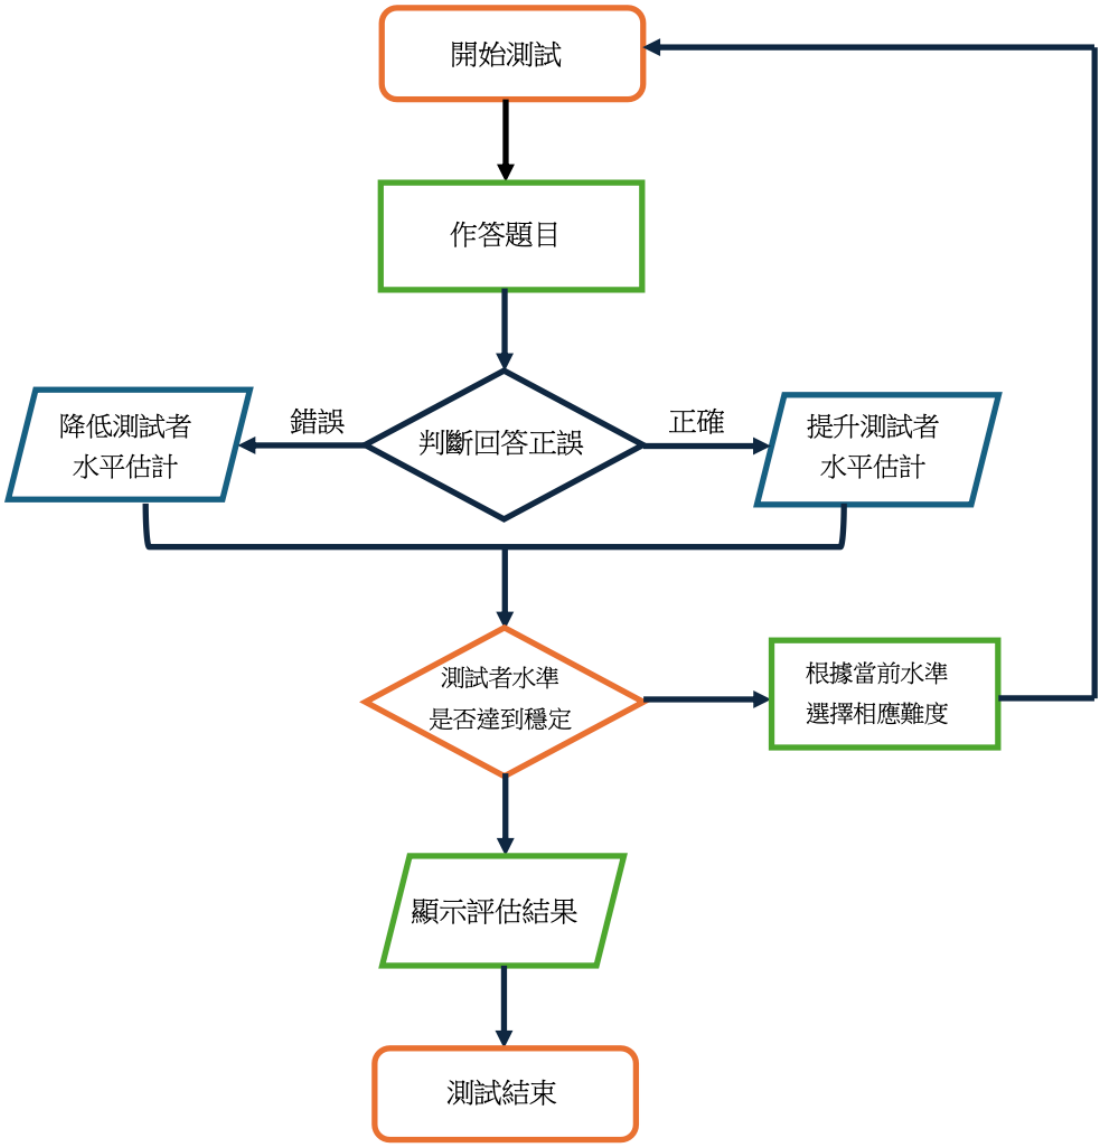

圖 1 分部評分模型演算法流程圖

具體實現方面，通過 Update_Ability_Level 演算法，研究者能夠根據測試者對題目的回答情況，動態調整其能力分數，並挑選出與當前能力水準相匹配的題目難度。 這種方法不僅提高了測試的個人化程度，還確保了評估結果的準確性和有效性。 偽代碼如圖 2：

算法：根據第 i 題答題情況更新答題者的答題水準
輸入：測試者能力分數，題目難度分數，答題正誤
輸出：更新后的測試者能力分數

```
Algorithm Update_ability_level:
begin
    stable = False    # Initialize stability flag
    updated_ability_score = ability_score
     # Set initial ability score for comparison
    stepSize = 0.1    # Set step size for adjustment of ability score
    # Main loop to adjust ability score until stability is achieved
    while not stable do
        for each question in questionBank do
         # Iterate through each question in the bank
            Ci = askQuestion(testTaker, question)
             # Ask the test taker the current question
            if isCorrect then    # Check if the answer is correct
                if questionDifficulty > abilityScore then
                 # If question difficulty is higher
                    abilityScore = abilityScore + stepSize
                     # Increase ability score
                else
                    if questionDifficulty < abilityScore then
                     # If question difficulty is lower
                        abilityScore = abilityScore - stepSize
                         # Decrease ability score
                    end if
                end if
                # Check for stability by comparing
                if abs(abilityScore - previousAbilityScore) < 0.001 then
                    stable = True    # Stability achieved
                else
                    previousAbilityScore = abilityScore
                     # Update previous ability score for next iteration
                end if
            end if
        end for
    end while
end
```

圖 2 偽代碼

2、機器評分的構建

通過與人工評分進行比較，本研究還探討了機器評分的可行性和實際效果。此次測試中，我們採用了兩種機器評分方法。

第一種方法基於權威英漢詞典、專家意見及測試者的答案，創建了一個具有廣泛適用性的答案庫。 機器評分首先對參與者的答案是進行清洗，然後將其與答案庫中的詞彙進行匹配。 為了減少拼寫錯誤對評分準確性的影響，我們將匹配條件設置為萊溫斯坦距離（Levenshtein Distance）≤1。

第二種機器評分方法中，我們選取了多個中文大模型，包括文心一言、Kimi、通義千問及豆包等。 首先，針對測試題目精心設計了一套標準化的 Prompt 提示詞體系，旨在清晰、準確地向大模型傳達評分任務的要求與要點。 接著，將題目以及被試的全部答案按照既定的格式與流程，輸入到選定的大模型之中。 隨後，將大模型給出的評分結果與人工評分進行對比分析，來檢驗在存在多個答案的複雜情況下，大模型的評判標準是否與人工評判具有一致性。

（三）測試對象與流程

1、測試對象

本次研究的測試者如表 1 所示：

表 1 測試者信息

批次	人數	性別	國籍	學歷	平均漢語學習時長	平均英語學習時長	漢語水準	英語水準
1	2 名	女	越南、馬來西亞	碩士	14 年	18.5 年	HSK6	IELTS>7
2	18 名	1 男 17 女	多為東南亞、東亞國家	7 碩士 11 本科	14.67 年	13.5 年	HSK6	IELTS≥7

								7 人; TOEFL≥90 2 人
3	6 名	4 男 2 女	多為英語國家	5 碩士 1 本科	10.5 年	15.83 年	HSK6	IELTS≥ 7 2 人; TOEFL≥90 1 人

被試的選取標準設定為漢語與英語高水準者，即需同時具備 HSK6 級水準及 IELTS、TOEFL 等國際標準化英語考試優秀等級（IELTS≥7，TOEFL≥90）。由於當前測試系統尚處於初步開發階段，內部架構、功能模組及評估機制均有待完善，故需要漢英高水準被試參與，提供具有針對性、建設性的反饋與建議。此外，其高質量的參考答案可作為系統評估準確性與有效性的重要參照。

第一批測試僅選取兩名被試的原因：一是旨在對測試時間予以多維度考量，除探究 1 小時的測試時長是否充裕外，也關注該時段內測試者是否會產生疲勞效應，確保測試時間設置的合理性。二是初步檢驗題目設置的合理性，考察題目是否需要進一步優化，以便及時發現潛在問題並及時調整，以提升測試題目的有效性與精準度。三是這兩名被試均為国际中文教育專業背景，且都具有較高的漢英水平，能夠對測試中的語境設計、字數設定以及目標詞選取等核心要素提出較為專業的建議。

2、測試流程

（1）第一輪測試

2 名被試需要在 1 小時內完成 270 道翻譯題，並在測試結束後提供反饋，為後續測試的題目修改提供參考依據。

（2）第二輪測試

18 名被試需要完成三個部分的任務。 首先是識字量測試，被試需進入線上會議，為每個漢字進行口頭組詞，該部分持續 3 分鐘。 其次是《漢英水平自評問卷》，被試需要對自己的英語和漢語水平進行自我評估，該部分持續 3 分鐘。 最後是《學術漢語測試問卷》，該部分包含 5 套問卷，共 260 道題，每套問卷包含 52 道題，每套問卷大約需要 10-15 分鐘。

（3）第三輪測試

在第二輪測試后，基於收集的數據，分析 260 道題目的區分度、難易度和信效度等，據此篩選出 70 道優質題並建立參考答案庫納入到系統中。

第三輪測試在此基礎上展開，6 名被試需要完成這 70 道題。 測試目的一是檢測系統運行效果，包括對不同能力被試的適應性等; 二是對比機器評分與人工評分異同，評估機器評分在學術漢語詞彙量測試中的可行性與準確性，為系統優化提供依據。

4 研究結果

（一）第 1 輪測試結果

在第一批被試完成試測后，綜合被試的反饋資訊與專家的專業建議，對測試內容進行了優化調整。 針對近義片語，經內部討論及參考了專家意見後，在每組近義詞中僅保留一個詞（如在「取代」與「替代」中，僅保留「取代」）。 此外，考慮到單音節詞在翻譯方面存在較大困難，故將其從研究範圍內排除，如單音節詞「限」。 同時，為確保測試的可推廣性與普適性，還刪除了部分專業性較強

的詞，如「對數」等。 經調整后，共刪掉 10 個詞，最終確定第二輪測試的題數為 260 道。

（二）第 2 輪測試結果

使用經典測量理論檢驗第二輪測試中 260 道題的信度、區分度與難易度。 一般認為，測試項目難易度應在 0.3~0.7 之間，區分度在 0.2 及以上，信度在 0.7 以上。結果顯示，第二次測試中的 260 道題總體信度（Cronbach α 系數）為 0.985，信度系數良好; 總體難易度為 0.66，難易度適中; 區分度為 0.44，區分度較好。此外，皮爾遜相關性分析結果顯示，第二輪學術詞彙量測試總得分與識字正確率顯著相關（$r=0.51$，$p=0.03<0.05$），這表明學術詞彙量測試的效標關聯效度較好。

（三）第 3 輪測試結果

基於第 2 輪測試結果，依據題目區分度、難易度與信效度等篩選出 70 道優質題，構建參考答案庫並納入系統（每題 1 分，滿分 70 分）。 第三輪測試由 6 名被試參與，以探究機器評分與人工評分的一致性。

經統計，人工評分數據依次為：61、67、66、64、60、68，其均值約為 64.33。機器評分數據分別為：60、67、64、64、61、68，均值為 64。 平均絕對誤差 MAE≈0.67，表明機器評分與人工評分在單個被試評分上的差異幅度較小。 均方誤差 MSE = 1，均方根誤差 RMSE = 1，進一步說明機器評分相對人工評分的偏離程度處於較低水準。 此外，通過相關性檢驗得出機器評分與人工評分之間顯著相關（$r\approx0.97$，$p=0.0013<0.05$）。 綜上所述，在評分標準明確的前提下，本研究中機器評分所得結果與人工評分具有高度一致性。

本研究還對比了大模型評分與人工評分的情況。 在這 70 道題里，大模型判定的最優答案與人工評判一致的有 57 道。 在其餘 13 道有差異的題目里，10 道

與人工次優答案一致，僅 3 道不一致。 這表明大模型經充分訓練后，確實具備一定的評分能力，且在大多數情況下能夠較好地類比人工評分邏輯。 但對於訓練集外題目，尤其是在多答案的複雜情境下，大模型評分可能與人工評判標準存在偏差。 但總體而言，大模型評分與人工評分仍呈現出較高的一致性，大模型在此類測試的評分中有一定的可靠性與應用價值。

5 結語

本研究基於經典測量理論的自適應模型為測試框架，初步開發了學術漢語詞彙量測試系統，並從多角度對該系統進行了評估。 結果顯示，最終測試試題的信度、效標關聯效度、區分度以及難度均良好，符合經典測量理論相關測量標準。 此外，機器評分也具有一定的可行性。

參考文獻

[1] 戴曼純（主編）（2023）：《國際中文教育發展報告》，北京，外語教學與研究出版社。

[2] 李加鎏（2024）：「漢語學術詞表的構建及應用」，《世界漢語教學》（03），395-406。

[3] 王笑然、王佶旻（2022）：「經貿類本科專業學術漢語詞表研究」，《語言教學與研究》（04），9-19。

[4] 張海威、張雪妍、張鐵軍、王睿昕（2021）：「留學生識字量表編制研究」，《世界漢語教學》（01），126-142。

[5] Coxhead， Averil (2000) A new academic word list. TESOL Quarterly 34 (2): 213-238.

[6] Gardner， D.， & Davies， M. (2015). A new academic vocabulary list. Applied Linguistics， 35， 305e327.

[7] Green， C. (2019). Enriching the academic wordlist and secondary vocabulary lists with lexicogrammar: Toward a pattern grammar of academic vocabulary. System， 87. https://doi.org/10.1016/j.system.2019.102158. Article 102158.

[8] Gyllstad， H.， Vilkaite， L.， & Schmitt， N. (2015). Assessing vocabulary size through multiple-choice formats: Issues with guessing and sampling rates. International Journal for Applied Linguistics， 166， 278-306.

[9] Lei， L.， & Liu， D. (2018). The academic English collocation list: A corpus-driven study. International Journal of Corpus Linguistics， 23， 216–243.

[10] Masaki Uto， Maomi Ueno (2016) Item response theory for peer assessment. IEEE Transactions on Learning Technologies， IEEE Computer Society， Vol.9， No.2， pp.157-170. [IF: 2.315]

[11] Masrai， A.， & Milton， J. (2018). Measuring the contribution of academic and general vocabulary knowledge to learners' academic achievement. Journal of English for Academic Purposes， 31， 44-57.

[12] Nation， I. S. P. (2001). Learning vocabulary in another language. Cambridge: Cambridge University Press.

[13] Nation， I. S. P.， & Coxhead， A. (2021). Measuring native-speaker vocabulary size. John Benjamins. https://doi.org/10.1075/Z.233

[14] Thompson， P.， & Alzeer， S. (2019). A survey of issues， practices and views related to corpus-based word lists for English language teaching and learning. International Journal of Applied Linguistics & English Literature， 8， 43–53.

[15] Webb， S.， Sasao， Y.， & Ballance， O. (2017). The updated Vocabulary Levels Test: Developing and validating two new forms of the VLT. ITL—International Journal of Applied Linguistics， 168(1)， 33–69. https://doi.org/10.1075/itl.168.1.02web

[16] Zhang， H.， Sun， P.， Bianglae， Y.， & Widiawati， W. (2024). The development of a Chinese vocabulary proficiency test (CVPT) for learners of Chinese as a second/foreign language. Language Testing. https://doi.org/10.1177/02655322231219998